


## 全新激活函数 Relu

近几年不再选择 sigmoid 或 tanh. 而是 relu

$$f(x) = \max(0, x)$$

Relu函数图像如下图所示:



优势: 1. 速度快

2. 减轻梯度消失问题

$$\nabla = \sigma' \delta x$$

Sigmoid 函数的导数

即每经过一个 Sigmoid 神经元就要乘一个  $\sigma'$

这样因为  $\sigma'$  最大值在 0.25, 这样越来越小

但是 Relu 的导数值为 1. 不会受到影响  
不会导致梯度变小

- **稀疏性** 通过对大脑的研究发现, 大脑在工作的时候只有大约5%的神经元是激活的, 而采用sigmoid激活函数的人工神经网络, 其激活率大约是50%。有论文声称人工神经网络在15%~30%的激活率时是比较理想的。因为relu函数在输入小于0时是完全不激活的, 因此可以获得一个更低的激活率。

## 全连接网络 VS 卷积网络

全连接神经网络之所以不太适合图像识别任务, 主要有以下几个方面的问题:

- **参数数量太多** 考虑一个输入 $1000 \times 1000$ 像素的图片(一百万像素, 现在已经不能算大图了), 输入层有 $1000 \times 1000 = 100$ 万节点。假设第一个隐藏层有100个节点(这个数量并不多), 那么仅这一层就有 $(1000 \times 1000 + 1) \times 100 = 1$ 亿参数, 这实在是太多了! 我们看到图像只扩大一点, 参数数量就会多很多, 因此它的扩展性很差。
- **没有利用像素之间的位置信息** 对于图像识别任务来说, 每个像素和其周围像素的联系是比较紧密的, 和离得很远的像素的联系可能就很小了。如果一个神经元和上一层所有神经元相连, 那么就相当于对于一个像素来说, 把图像的所有像素都等同看待, 这不符合前面的假设。当我们完成每个连接权重的学习之后, 最终可能会发现, 有大量的权重, 它们的值都是很小的(也就是这些连接其实无关紧要)。努力学习大量并不重要的权重, 这样的学习必将是非常低效的。
- **网络层数限制** 我们知道网络层数越多其表达能力越强, 但是通过梯度下降方法训练深度全连接神经网络很困难, 因为全连接神经网络的梯度很难传递超过3层。因此, 我们不可能得到一个很深的全连接神经网络, 也就限制了它的能力。

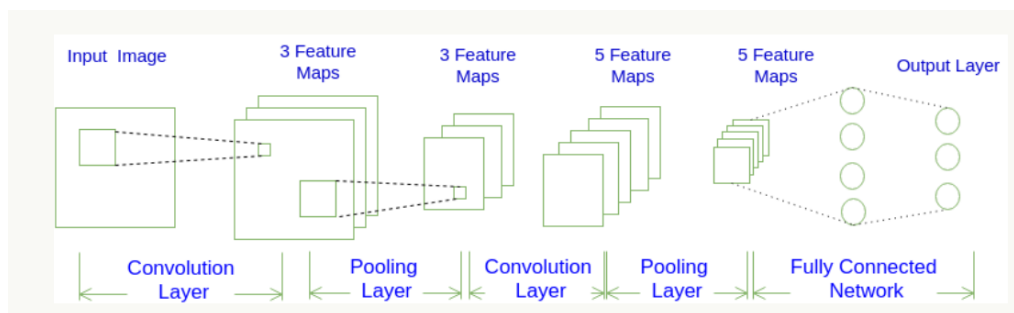
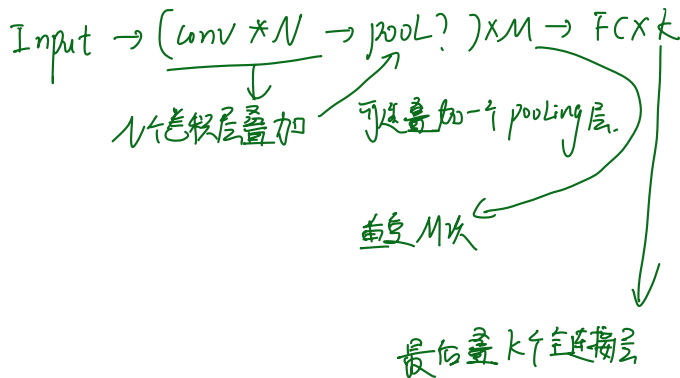
那么, 卷积神经网络又是怎样解决这个问题的呢? 主要有三个思路:

- **局部连接** 这个是最容易想到的, 每个神经元不再和上一层的所有神经元相连, 而只和一小部分神经元相连。这样就减少了很多参数。
- **权重共享** 一组连接可以共享同一个权重, 而不是每个连接有一个不同的权重, 这样又减少了很多参数。
- **下采样** 可以使用Pooling来减少每层的样本数, 进一步减少参数数量, 同时还可以提升模型的鲁棒性。

对于图像识别任务来说, 卷积神经网络通过尽可能保留重要的参数, 去掉大量不重要的参数, 来达到更好的学习效果。

## 卷积神经网络

卷积层, pooling层, 全连接层



Input  $\rightarrow$  conv  $\rightarrow$  pool  $\rightarrow$  conv  $\rightarrow$  pool  $\rightarrow$  FC  $\rightarrow$  FC



Input  $\rightarrow$  [conv  $\rightarrow$  pool]  $\times 2 \rightarrow$  FC  $\times 2$

$N=1$   $M=2$   $K=2$

### 三维层结构

全连接网络为一维排列

卷积为三维  $\longrightarrow$  长宽高

图片中看出

1个卷积层  $\rightarrow$  3个 Filter (得3个 Feature Map)  
 $\downarrow$   
3个通道

Pooling层在另一个卷积层后又对3个 Feature Map采样  
(取了3个小的)


第2个卷积层  $\rightarrow$  有5个 Filter

每个 Filter 部将前3个采样是在一起算的 Feature Map.

5个 Feature Map

第2个 pooling 变成 5 个小的 Feature Map

卷积层输出值计算



想这样，用  $X_{ij}$  表示第  $i$  行  $j$  列元素。

对 filter 每个权重编号

而用  $W_{m,n}$  表示第  $m$  行  $n$  列权重用  $W_b$  表示 filter 偏置

用  $a_{ij}$  表示 Feature Map 元素

卷积核



$$a_{ij} = f \left( \sum_{m=0}^2 \sum_{n=0}^2 W_{m,n} X_{i+m, j+n} + W_b \right) \quad (W \times b)$$

Feature Map 左上角  $a_{0,0}$  的计算方法为

$$a_{0,0} = f \left( \sum_{m=0}^2 \sum_{n=0}^2 W_{m,n} X_{m,n} + W_b \right)$$

$$= \text{relu} (W_{0,0} X_{0,0} + W_{0,1} X_{0,1} + W_{0,2} X_{0,2} + W_{1,0} X_{1,0}$$

$$+ W_{1,1} X_{1,1} + W_{1,2} X_{1,2} + W_{2,0} X_{2,0} + W_{2,1} X_{2,1} + W_{2,2} X_{2,2} + W_b)$$



$$\begin{aligned}
 &= \text{relu} (1+0+1+0+1+0+0+0+1+0) \\
 &= \text{relu}(4) = 4 \quad \text{if } 0, 0 \neq 4
 \end{aligned}$$

for  $a_{0,1}$  is

$$f\left(\sum_{m=0}^2 \sum_{n=0}^2 W_{m,n} X_{m+0, n+1} + W_b\right)$$

$$\begin{aligned}
 &= \text{relu}(W_{0,0} X_{0,1} + W_{0,1} X_{0,2} + W_{0,2} X_{0,3} + W_{1,0} X_{1,1} \\
 &+ W_{1,1} X_{1,2} + W_{1,2} X_{1,3} + W_{2,0} X_{2,1} + W_{2,1} X_{2,2} \\
 &+ W_{2,2} X_{2,3} + W_b)
 \end{aligned}$$

$$\begin{aligned}
 &= \text{relu}(1 \times 1 + 0 \times 1 + 1 \times 0 + 0 \times 1 + 1 \times 1 \\
 &+ 0 \times 1 + 1 \times 0 + 0 \times 1 + 1 \times 1 + W_b)
 \end{aligned}$$

$$= \text{relu}(1+0+0+0+1+0+0+0+1)$$

$$= \text{relu}(3) = 3 \quad \text{if } (0,1) = 3$$

修改后的 Feature Map

4	3	F
2	4	3
2	3	0

计算结果

当步幅为2时 feature Map 变为 2x2 的

那么如何计算是几呢

$$W_2 = \frac{(W_1 - F + 2P)}{S + 1}$$

↓                      ↓                      ↗  
卷积宽度          Filter 数          步幅

$$= (5 - 3 + 0) / 2 + 1$$

$$= 2$$